Estimación de Estados Aplicada a Modelos de Cultivos

Zuluaga P. Emanuel * **García O. César.** **

* *Departamento de Energía Eléctrica y Automática, Facultad de Minas, Universidad Nacional sede Medellín, ANT 050034 Colombia (e-mail: ezuluagap@unal.edu.co).*
** *Departamento de Energía Eléctrica y Automática, Facultad de Minas, Universidad Nacional sede Medellín, ANT 050034 Colombia (e-mail: cegarciao@unal.edu.co).*

Abstract: This paper presents state estimators for a mathematical model based on the SPAC (Soil–Plant–Atmosphere–Continuum) concept, which incorporates three equations describing the dynamics of plant biomass, internal plant water, and soil-available water López-Jiménez et al. (2022) and Díaz-González et al. (2022). Analytical expressions for observability and for the equilibrium point are derived in order to linearize the system around this point and obtain the state-space matrices required for estimator design.

Keywords: SPAC, state estimator, model, observability, linearization, irrigation control, equilibrium point.

1. INTRODUCCIÓN

El objetivo de este trabajo es analizar un modelo dinámico partiendo del concepto SPAC, el cual permite formular las interacciones físicas entre el suelo, la planta y la atmósfera, pero especialmente se busca responder a la pregunta: ¿Cómo se pueden estimar los estados de un modelo matemático basado en el concepto SPAC (Soil–Plant–Atmosphere–Continuum), que incluye la biomasa, el agua interna de la planta y el agua disponible en el suelo.

Este trabajo utiliza un modelo dinámico compuesto por 3 ecuaciones que representan el concepto SPAC en el crecimiento de la biomasa, el contenido hídrico interno de la planta y la humedad disponible en el suelo, a partir de allí se determina observabilidad y puntos de equilibrio, se linealiza el sistema alrededor de estos puntos para obtener las matrices en espacio de estados requeridas para el diseño del diferentes estimadores.

El modelo planteado en este artículo consta de un sistema no lineal de tres ecuaciones de balance de masa y energía que describen la dinámica de la biomasa, el agua interna de la planta y el agua disponible en el suelo. Este modelo es usado por los autores Díaz-González et al. (2022), el cual coincide exactamente con el modelo presentado por los autores López-Jiménez et al. (2022).

2. PRESENTACIÓN DEL MODELO, LINEALIZACIÓN Y OBSERVABILIDAD

En esta parte, se presentará de forma detallada el modelo hidrológico basado en el modelo SPAC mencionado en la sección de introducción, modelo tomado de los artículos presentados por Díaz-González et al. (2022) y López-Jiménez et al. (2022).

Según los investigadores Díaz-González et al. (2022), el modelo en variables de estado presentado puede ser aplicado a diversos tipos de cultivo, sin embargo, los diferentes parámetros embebidos en este varían ampliamente. Bajo esta perspectiva, los autores aplican el modelo a temporadas de cultivo de trigo de 300 días, donde los primeros 200 días se realizaba riego, distribuido en un periodo de 32 días, con riegos diarios y una aplicación de 30 unidades de volumen por riego. En este modelo se considera el agua como único factor limitante, ignorando por completo nutrientes del suelo, fertilizantes, entre otros. Al evaluar los cambios en el riego, se determina el agua disponible en el suelo, lo cual, afecta el agua interna de la planta y la acumulación de materia seca (biomasa).

2.1 Presentación del modelo y explicación de los parámetros

Ecuaciones del modelo: Las dinámicas SPAC del modelo están definidas en el sistema de ecuaciones (1) mostrado a continuación:

$$\begin{cases} x'(t) = \dfrac{\kappa\, x(t)\, \omega(t)}{1 + g\, x(t)} - m\, x(t), \\ \omega'(t) = \dfrac{\delta\, \omega(t)\, v(t)}{1 + r\, \omega(t)} - \beta\, \omega(t) - \dfrac{k\, x(t)\, \omega(t)}{1 + g\, x(t)}, \\ v'(t) = -\gamma\, v(t) - \rho\, \dfrac{\omega(t)\, v(t)}{1 + r\, \omega(t)} + u. \end{cases} \tag{1}$$

Explicación y parámetros del modelo: Las variables de estado del modelo se definen de manera que $x(t)$ representa la biomasa aérea de la planta, $\omega(t)$ corresponde al contenido de agua interna en la planta, y $v(t)$ denota el agua disponible en el suelo. La entrada externa u modela el aporte de agua al suelo, ya sea por riego o por precipitación. En resumen:

$x(t)$	Biomasa aérea de la planta.
$\omega(t)$	Agua interna en la planta.
$v(t)$	Agua disponible en el suelo.
u	Entrada de agua externa (riego/lluvia).

2.2 Dinámica del agua en el suelo

El suelo se modela como un depósito ("pond") con una capacidad máxima $v_{\max}$. Su dinámica está gobernada por dos procesos principales:

(1) Evaporación directa: pérdida proporcional a la cantidad de agua en el suelo, con tasa γ.
(2) Absorción de agua por la planta: ocurre a una tasa dependiente de $\omega(t)$, la cantidad de agua en la planta, y presenta saturación para valores grandes de $\omega(t)$ (tipo Michaelis–Menten o Monod).

La dinámica del agua en el suelo se describe como:

$$v'(t) = -\gamma v(t) - \rho \left(\frac{\omega(t)}{1 + r\,\omega(t)} \right) v(t) \tag{2}$$

donde:

- γ: tasa de pérdida por evaporación,
- ρ: tasa de flujo de agua hacia la planta,
- r: constante de saturación que regula cuánto afecta el agua interna ω a la absorción.

En este sentido, la dinámica del agua en el suelo debe cumplir que el contenido hídrico permanezca positivo, es decir, $v(t) > 0$, evitando simultáneamente alcanzar niveles de saturación superiores al valor máximo permitido $v_{\max}$. En otras palabras, el suelo debe mantenerse entre el Punto de Marchitez Permanente (PWP) y la Capacidad de Campo (FC), sin superar el umbral de saturación.

2.3 Dinámica del agua dentro de la planta

El agua presente en la planta varía debido a dos causas:

(1) Absorción desde el suelo, proporcional a la interacción entre $v(t)$ y $\omega(t)$.
(2) Pérdidas por transpiración y uso en el crecimiento.

La dinámica de $\omega(t)$ se modela como:

$$\omega'(t) = \delta \left(\frac{\omega(t)}{1 + r\,\omega(t)} \right) v(t) - \beta\omega(t) - \mu G(x)\,\omega(t) \tag{3}$$

donde:

- δ: tasa de absorción desde el suelo,
- β: tasa de pérdida por transpiración,
- μ: tasa de uso de agua en la formación de biomasa,
- $G(x)$: función de ganancia de masa seca (definida más adelante).

De este modo, la dinámica del agua dentro de la planta debe permanecer acotada en todo momento, cumpliendo $0 \leq \omega(t) \leq \omega_{\max}$. Esto garantiza que la planta recibe suficiente agua para sostener la transpiración y el crecimiento, sin acumular niveles que fisiológicamente no son posibles.

2.4 Dinámica del crecimiento de la planta (biomasa)

El crecimiento de la planta se modela como la diferencia entre una ganancia neta y una pérdida:

$$x'(t) = \sigma \frac{x(t)}{1 + gx(t)} - mx(t) \tag{4}$$

donde:

- σ: tasa intrínseca de crecimiento (asimilación neta),
- g: factor limitante de crecimiento (tipo logística modificada),
- n: exponente que regula la velocidad o forma sigmoidal del crecimiento,
- m: tasa de degradación o muerte de tejido vegetal.

La función de ganancia $G(x)$ utilizada en la ecuación del agua en la planta se define como:

$$G(x) = \vartheta \frac{x}{1 + g} \tag{5}$$

Esta función $G(x)$ acopla directamente el uso del agua con el crecimiento del cultivo mediante el término $\mu G(x)\,\omega(t)$ en la ecuación de $\omega(t)$.

También, la dinámica de la biomasa debe respetar su naturaleza fisiológica, permaneciendo no negativa y limitada superiormente por el potencial de crecimiento del cultivo, esto es, $0 \leq x(t) \leq x_{\max}$. Esta condición refleja que la biomasa solo puede aumentar mientras exista agua disponible y jamás disminuir por debajo de cero.

2.5 Valores de parámetros

Para este trabajo, los valores de los parámetros no fueron obtenidos directamente de los valores ilustrativos presentados en el artículo *How Does Irrigation Affect Crop Growth? A Mathematical Modeling Approach* (Díaz-González et al., 2022) donde se mostraban parámetros de ejemplo para el análisis matemático. En cambio, siguiendo la metodología de calibración propuesta por los autores basada en el ajuste de curvas a datos experimentales reales y aplicada en la sección de validación del modelo, utilizando datos de trigo provenientes de Andarzian et al. (2011) y el enfoque estadístico sugerido por Mayer y Butler (1993) para la estimación de parámetros, los utilizados en este caso fueron obtenidos mediante un proceso de calibración independiente, ajustando los parámetros de acuerdo con los resutlados que mejor evidenciaran el correcto funcionamiento del modelo simulado. De esta manera, los valores reportados aquí corresponden a una calibración propia ejecutada específicamente para el conjunto de datos empleado, garantizando coherencia con el procedimiento recomendado en el artículo original y recordando que, de igual forma, los valores acá mostrados tienen un enfoque ilustrativo los cuales pueden variar ampliamente de acuerdo con el tipo de cultivo estudiado; a continuación se listan los valores de los mismos:

$$
\begin{aligned}
\kappa &= 0.99373 \\
g &= 0.10390 \\
m &= 1.07359 \\
\delta &= 1.02885 \\
r &= 1.22763 \\
\beta &= 1.3547 \\
k &= 0.01003 \\
\gamma &= 0.00001 \\
\rho &= 0.01146
\end{aligned}
$$

2.6 Puntos de equilibrio y entradas de riego

Para determinar los puntos de equilibrio del sistema, se sigue el procedimiento estándar de la teoría de sistemas dinámicos: un punto de equilibrio es aquel en el que las variables de estado permanecen constantes en el tiempo. Esto equivale a imponer que todas las derivadas temporales sean iguales a cero, es decir:

$$\dot{x} = 0, \qquad \dot{\omega} = 0, \qquad \dot{v} = 0. \tag{6}$$

Al aplicar la condición al modelo previamente establecido (1), se obtiene el siguiente sistema algebraico que deben satisfacer las componentes del punto de equilibrio (x^*, ω^*, v^*):

$$
\begin{cases}
0 = \dfrac{\kappa\, x^*(t)\, \omega(t)}{1 + g\, x^*(t)} - m\, x^*(t), \\
0 = \dfrac{\delta\, \omega^*(t)\, v^*(t)}{1 + r\, \omega^*(t)} - \beta\, \omega^*(t) - \dfrac{k\, x^*(t)\, \omega^*(t)}{1 + g\, x^*(t)}, \\
0 = -\gamma\, v^*(t) - \rho\, \dfrac{\omega^*(t)\, v^*(t)}{1 + r\, \omega^*(t)} + u.
\end{cases} \tag{7}
$$

Obsérvese que el sistema (7) está compuesto por tres ecuaciones algebraicas, pero contiene cuatro incógnitas: las tres variables de equilibrio

$$x^*, \quad \omega^*, \quad v^*$$

y además el parámetro de entrada u. Por esta razón, el sistema está subdeterminado y no es posible encontrar un punto de equilibrio único a menos que se fije el valor de u. Por tanto, para poder resolver el sistema y obtener los puntos de equilibrio, se establece que la entrada toma un valor constante,

$$u = \bar{u},$$

y bajo esta condición las tres ecuaciones de (7) se pueden resolver para determinar los valores de equilibrio (x^*, ω^*, v^*). Este procedimiento permite obtener los diferentes puntos de equilibrio del modelo, según los casos particulares que surjan de las soluciones del sistema.

$$\mathbf{p}_0 = (0, 0, 0), \tag{8}$$

$$\mathbf{p}_1 = \left(0,\ -\frac{\gamma}{\varepsilon},\ \frac{\beta\,\rho}{\delta\,\varepsilon}\right), \tag{9}$$

$$\mathbf{p}_2 = \left(-\frac{\beta}{k + \beta g},\ \frac{k\,m}{\kappa\,(k + \beta g)},\ 0\right), \tag{10}$$

$$\mathbf{p}_3 = \left(-\frac{1}{m}\left(\frac{\kappa\gamma}{\varepsilon} + m\right),\ -\frac{\gamma}{\varepsilon},\ \frac{k\rho}{\kappa g \delta \gamma \varepsilon}(g\beta\gamma + k\kappa\gamma + m\varepsilon)\right). \tag{11}$$

Existen diferentes niveles de riego (entrada del sistema) que ubican la cantidad de agua suministrada al cultivo de acuerdo a múltiples factores como las características del cultivo, las condiciones climáticas y ambientales, la temporada del año, etc. Bajo esta consideración, es necesario seleccionar el nivel o niveles de riego para poder hallar los puntos de equilibrio los cuales son necesarios para la linealización. Los niveles de riego fueron mencionados por fuentes como FAO (2015); Díaz-González et al. (2022); Allen et al. (1998); Andarzian et al. (2011); Waller and Yitayew (2015); Romero et al. (2018), entre otros. Todos los autores coinciden en que para un cultivo de trigo con condiciones similares a las supuestas en este trabajo, es posible tener diferentes niveles de riego de acuerdo a la disponibildad de agua y condiciones climáticas durante el ciclo de cultivo.

Con el fin de representar de forma un poco más fiel el carácter del sistema en relación con el cultivo elegido, se han seleccionado 3 niveles de riego alrededor de los cuales se linealiza.

Escenario A (riego pleno): Se define un riego pleno con completa disponibilidad de agua en entornos donde el cultivo lo requiere, este oscila entre 3.5 4.5 mm/día; para este escenario se optó por un riego de *4.0 mm/día*

Riego 2 (riego suplementario): Riego intermedio, da soporte pero posiblemente con aporte adicional por lluvia o retención de suelo, este se encuentra entre 2.0 3.0 mm/day; para este escenario se optó por in riego de *2.5 mm/día*

Riego 3 (riego deficitario): Riego estratégico, limitado, para maximizar eficiencia y priorizar las etapas críticas, el rango estimado se encuentra entre 1.0 2.0 mm/day; para este escenario se optó por in riego de *1.5 mm/día*

2.7 Linealización del modelo y análisis de los valores propios

Recordemos que se tiene un sistema de la forma:

$$\dot{x} = f(x, u), \qquad y = h(x, u) \tag{12}$$

Para realizar la linealización y luego de haber hallado los puntos de equilibrio los cuales son fundamentales para centrar nuestras variables de desviación, se procede a calcular las matrices A, B y C de nuestro sistema lineal mediante el jacobiano las cuales capturan la pendiente local del sistema no lineal alrededor del punto de operación. Son

equivalentes a calcular la recta tangente en cálculo, pero ahora generalizado para sistemas multivariables.

$$\begin{aligned} A &= \left.\frac{\partial f}{\partial x}\right|_{(x_e,u_e)}, \qquad B = \left.\frac{\partial f}{\partial u}\right|_{(x_e,u_e)}, \\ C &= \left.\frac{\partial h}{\partial x}\right|_{(x_e,u_e)}, \qquad D = \left.\frac{\partial h}{\partial u}\right|_{(x_e,u_e)}. \end{aligned} \tag{13}$$

Recordemos que nuestras varaibles de desviación "centran" o "desplazan" mi variable alrededor del punto que queremos linealizar:

$$\tilde{x} = x - x_e, \qquad \tilde{u} \;\; = u - u_e, \qquad \tilde{y} = y - y_e. \tag{14}$$

Finalmente, nuestro sistema linealizado queda con la siguiente estructura:

$$\dot{\tilde{x}} = A\,\tilde{x} + B\,\tilde{u}, \qquad \tilde{y} \;\; = C\,\tilde{x} + D\,\tilde{u}. \tag{15}$$

Se ha implementado un código el cual calcula los puntos de equilibrio en función de la entrada para luego calcular las matrices A, B y C del sistema lineal. Adicionalmente, este código calcula la solución del sistema no lineal con el fin realizar una comparativa entre ambos modelos. A continuación se muestran la matrices obtenidas para cada uno de los puntos de equilibrio junto con el análisis de los valores propios:

- *Riego de 4.0 mm/día (escenario A, $u = 4.0$):*

$$A = \begin{bmatrix} -1.0689 & 9.5225 & 0 \\ -0.0000 & -1.4460 & 0.8353 \\ 0 & -0.0001 & -0.0093 \end{bmatrix} \tag{16}$$

$$\lambda = \begin{bmatrix} -1.0701 \\ -1.4448 \\ -0.0093 \end{bmatrix} \tag{17}$$

- *Riego de 2.5 mm/día (escenario B, $u = 2.5$):*

$$A = \begin{bmatrix} -1.0661 & 9.4974 & 0 \\ -0.0001 & -1.4430 & 0.8337 \\ 0 & -0.0001 & -0.0093 \end{bmatrix} \tag{18}$$

$$\lambda = \begin{bmatrix} -1.0680 \\ -1.4410 \\ -0.0093 \end{bmatrix} \tag{19}$$

- *Riego de 1.5 mm/día (escenario C, $u = 1.5$):*

$$A = \begin{bmatrix} -1.0548 & 9.3973 & 0 \\ -0.0002 & -1.4307 & 0.8272 \\ 0 & -0.0002 & -0.0092 \end{bmatrix} \tag{20}$$

$$\lambda = \begin{bmatrix} -1.0596 \\ -1.4258 \\ -0.0093 \end{bmatrix} \tag{21}$$

Al analizar la matriz A y los valores propios de esta en cada uno de los niveles de riego seleccionado, se observa que todos los valores propios de la matriz son negativos. Bajo el criterio de estabilidad de sistemas LTI, se puede concluir que este sistema es entonces *asintóticamente estable* en lazo abierto.

Además, la constante de tiempo τ es un parámetro que describe la rapidez de la respuesta de un sistema dinámico. Para sistemas de primer orden, τ corresponde al tiempo necesario para que la respuesta alcance aproximadamente el 63.2% de su valor final.

$$\tau = -\frac{1}{\mathrm{Re}(\lambda_{\mathrm{dom}})}, \tag{22}$$

En sistemas de orden superior, la constante de tiempo se asocia con el *polo dominante*, es decir, el inverso del valor propio más cercano al eje imaginario y el tiempo de establecimiento T_s como 4 veces dicha constante de tiempo, tal que:

$$T_s \approx 4\,\tau. \tag{23}$$

El polo dominante de la planta en lazo abierto en los tres puntos de equilibrio es $u = 0.0093$, con la ecuación (23) se puede calcular el tiempo de establecimiento de la planta en lazo abierto siendo $T_s \approx 430$ días.

2.8 Resultado de las simulaciones

En esta sección se mostrarán los resultados del modelo linealizado en los puntos de equilibrio en contraste con el modelo original (no lineal) de la planta para un tiempo total de 500, pues a pesar de que el ciclo estándar de cultivo de trigo con las condiciones supuestas en el artículo original es de 120 días, este periodo no es suficiente para mostrar una estabilziación teórica del modelomatemático de la planta.

El código de linealización mencionado en el apartado anterior permite comparar fácilmente ambos modelos. Adicionalmente, en un determinado tiempo t se introduce una perturbación en la entrada para conocer a detalle el comportamiento del modelo lineal verificando la fidelidad de la respuesta del modelo lineal respecto al original alrededor del punto de equilibrio.

A continuación, se presentan los resultados de los tres puntos seleccionados de riego para los cuales se calculó el equilibrio:

- *Riego de 4.0 mm/día (escenario A):* La magnitud de la perturbación para este caso es de 2 mm/día, ubicando la entrada final en 6 mm/día.

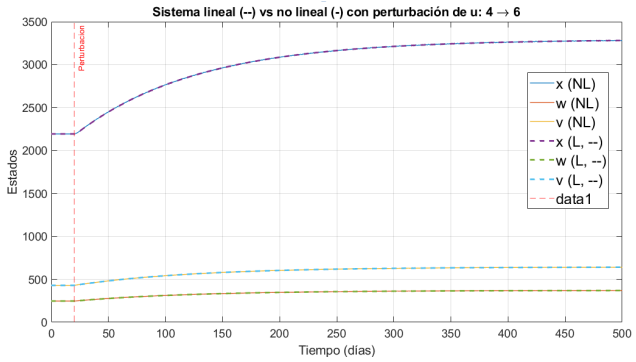

Fig.1 Modelo lineal vs no lineal con riego de 4.0.

- *Riego de 2.5 mm/día (escenario B):* La magnitud de la perturbación para este caso es de 1.5 mm/día, ubicando la entrada final en 4 mm/día.

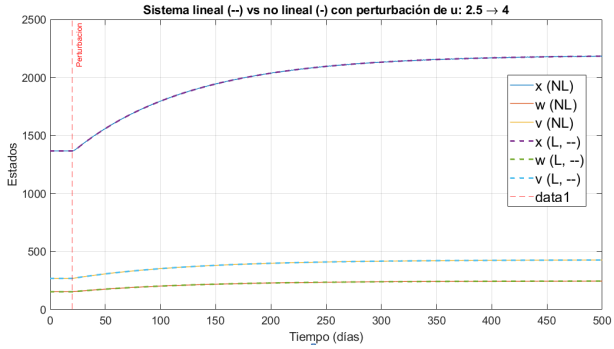

Fig.2 Modelo lineal vs no lineal con riego de 2.5.

- *Riego de 1.5 mm/día (escenario B):* La magnitud de la perturbación para este caso es de 1 mm/día, ubicando la entrada final en 2.5 mm/día.

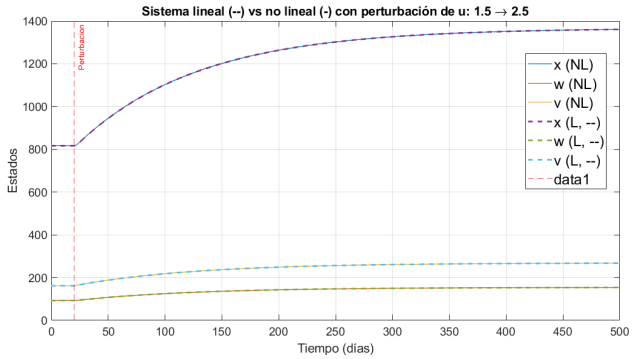

Fig.3 Modelo lineal vs no lineal con riego de 1.5

Tanto el sistema lineal como no lineal parten en el punto de equlibrio, al introducir una perturbación en la entrada para ambos sistemas, el sistema lineal emula fielmente la respuesta del sistema original siendo esta casi perfecta.

El error muestreado para cada punto del sistema evidencia el correcto comportamiento del sistema lineal siendo este acotado por un valor aproximado de 0.14% para cada variable de estado en proporción a las magnitudes de operación del sistema. Es decir, el máximo error porcentual del modelo lineal respecto al no lineal puede ser acotado por este valor mencionado anteriormente para cada variable de estado en cada punto de operación probado.

2.9 Observabilidad

Para un sistema LTI como el modelo linealizado propuesto, es posible demostrar la observabilidad del sistema mediante el ciretrio de Kalman de observabilidad, el cual indica que el sistema es observable si y solo si la matriz de observabilidad debe tener rango completo.

Al linealizar, la matriz A y los equilibrios del modelo resultan en función de la entrada seleccionada de equilibrio (entrada de riego u_{eq}), de tal forma que la matriz de observabilidad queda también en función esta.

Dado que, una matriz tiene rango completo cuando su determinante es diferente de cero, podemos plantear una ecuación matricial para buscar los valores de la entrada de equilibrio (u_{eq}) en los cuales el determinante es igual a cero, encontrando así los valores para los cuales el sistema NO es observable:

Realizar esta de forma manual tarea es compleja y tediosa, por lo que se diseñó un código que prueba la observabilidad y busca dichos valores. Este linealiza el sistema y calcula los puntos de equilibrio y la matriz A en función de la entrada u_{eq}, resuelve la ecuación buscando los valores u_{eq} para los cuales el sistema no tiene rango completo y seleccionando únicamente aquellos que son válidos (valores negativos son excluidos puesto que no son físicamente alcanzables).

Al realizar la prueba, se encuentra que únicamente existe un valor para u_{eq} en el cual, el sistema no es observable:

$$u_{no} = 0.01633271$$

Sin embargo, al probar con valores entre los rangos típicos seleccionados para entrada de equlibrio (escenarios explicados en el sistema de ecuaciones (7)), se obtienen valores diferentes de 0 para el determinante de la matriz de observabilidad, permitiendo concluir que el sistema es observable en estos rangos.

Para facilitar el análisis, a partir de este punto se comenzará a desarrollar el trabajo con un único punto de operación fijado en $u_{eq} = 2.5$ mm/día, sin embargo, los resultados obtenidos para este se pueden replicar en cualquier punto del rango típico de riego.

A continuación, se muestra el resultado del derminante de la matriz de observabilidad y el rango de la misma para dicho punto de operación. Se puede concluir que el sistema es completamente observable alrededor de este punto de operación:

$$rango = 3 \tag{24}$$
$$det(A) = 75.19948 \tag{25}$$

Criterio de observabilidad para Luengerberg

El criterio de observabilidad de Kalman puede ser extrapolado al criterio de observabilidad de Luengerberg, es decir, basta con calcular la matriz de observabilidad del par (A,C) y verificar que el rango sea completo, en ese caso, se puede diseñar un observador de luengerberg con ganancias ajustables las cuales modifican los valores propios del observador cambiando la dinámica del mismo.

Dado que ya se mostró al inicio de este apartado la observabilidad de nuestro modelo linealizado con el par (A,C), se puede concluir observabilidad para Luengerberg.

Criterio de observabilidad para observador con entradas desconocidas

Como se explicó al comienzo de este apartado, la matriz A depende directamente de la entrada u_{eq}. Si se buscara obtener los valores u_{eq} para los cuales el sistema no es observable, el procedimiento sería similar con la diferencia de que se debería acarrear dicha dependencia de u_{eq} para cada una de las matrices que se deben calcular para este observador y probar su observabilidad. Dado que este proceso es tedioso y redundante, nos enfocamos en el punto $u_{eq} = 2.5$ mm/día como se mencionó anteriormente.

Inicialmente para diseñar este observador se debe demostrar la condición de enfrentamiento, es decir, el rango de la matriz $C * D$ debe ser igual al número de entradas desconocidas, es decir, que existe visibilidad en las salidas de dichas entradas desconocidas:

Para cumplir este objetivo se tuvo que modificar la variable medida de tal forma que la matriz C tomó la forma:

$$C = [\,0\ 0\ 1\,] \tag{26}$$

Ahora bien, para mostrar la observabilidad en este caso debemos mostrar que el rango del par (PA,C) es completo, el cual es calculado de la siguiente forma:

$$E = -D(CD)^{-1} \tag{27}$$

$$P = I + EC \tag{28}$$

$$\text{rank}(\mathcal{O}_{PA,C}) = n. \tag{29}$$

$$\mathcal{O}_{PA,C} = \begin{bmatrix} C \\ C(PA) \\ C(PA)^2 \end{bmatrix} \in R^{3\times 3} \tag{30}$$

Al evaluar dicho criterio de observabilidad, se obtiene que el sistema como tal no es observable para el observador de entradas desconocidas, sin embargo, es posible diseñar el observador puesto que este cumple las condiciones de detectabilidad.

Al extraer los valores propios de la matriz de observabilidad, se obtiene estos son negativos y únicamente uno de ellos es problemático, y dado que el rango de nuesta matriz de observabilidad es 1, es posible cambiar este valor de tal forma que la matriz completa es asintóticamente estable y por ende, la dinámica del error también lo es.

$$P * A = \begin{bmatrix} -1.0661 & 9.4974 & 0 \\ -0.0001 & -1.4430 & 0.8337 \\ 0 & 0 & 0 \end{bmatrix}$$

$$rango(P * A) = 2$$

$$\lambda = \begin{bmatrix} -1.0680 \\ -1.4410 \\ 0 \end{bmatrix}$$

3. OBSERVADOR DE LUENGERBERG

Para diseñar un observador de Luengerberg utilizamos el errror de estimación y su derivada, pudiendo ubicar los polos del sistema a valores deseados con el vector de ganancias K_e

Ahora bien, el criterio de ubicación de polos para el observador se ha tomado teniendo en cuenta que el polo dominante del observador (el que está más cerca del origen) esté ubicado al menos 3 veces más lejos del polo dominante de la planta. De esta manera, se busca que el error de estimación del observador converja considerablemente más rápido que la planta, tal que:

$$P_{\min} = \min\big(\text{Re}(\lambda_i(A))\big) \tag{31}$$

$$P_{\text{obs}} = \{\, 3p_{\min},\ 4p_{\min},\ 5p_{\min} \,\} \tag{32}$$

Nuestro polinomio deseado quedaría entonces:

$$P_{\text{deseado}}(s) = (s - 3\lambda)(s - 4\lambda)(s - 5\lambda) \tag{33}$$

A continuación se muestran los resultados obtenidos para los polos deseados y el tiempo de convergencia estimado en base al polo dominante. Recuerde que el tiempo de convergencia se calcula 4 veces la constante de tiempo que es a su vez el inverso del polo dominante:

$$\lambda_{min} = -1.4410$$
$$\lambda_{deseados} = \begin{bmatrix} -4.3230 \\ -5.7640 \\ -7.2049 \end{bmatrix}$$

$$t_s = -0.9253$$
$$t_{splanta} = -428.0201$$

Recordamos que estos valores están dados para una linealización con una entrada de riego $u_{eq} = 2.5$.

Se observa que, en efecto, el error de estimación del observador converge considerablemente más rápido que la planta, permitiendo obtener una estimación rápida y precisa sin perder gran parte de la dinámica de la planta.

Ahora bien, se calculan las ganancias del observador tal que:

$$\det(sI - (A - K_eC)) = P_{\text{deseado}}(s) \tag{34}$$

Utilizando el comando place para calcular las ganancias en función de nuestros polos tenemos que:

$$K_e = \begin{bmatrix} 14.7735 \\ 7.8522 \\ 22.5592 \end{bmatrix}$$

3.1 Resultados de simulación

A continuación muestran los resultados con un error de estimación inicial con el fin de verificar la convergencia del error de estiamción a cero y la efectiva estimación de los estados.

Cabe aclarar que, de este punto en adelante, se mostrarán los resultados en un intervalo de máximo 5 días puesto que nuestro observador converge considerablemente rápido en comparación del tiempo de establecimiento de la planta. Además, se evita mostrar el proceso de estabilización de la planta, en la sección anterior (resultados de linealización) se muestran los resultados de converencia de la planta.

Error inicial de estimación diferente de cero:

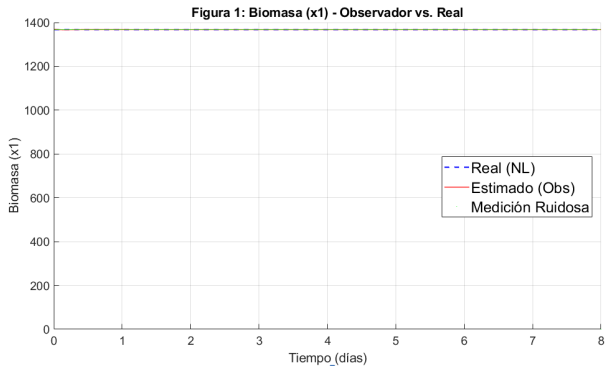

Fig.4 Estimación de x

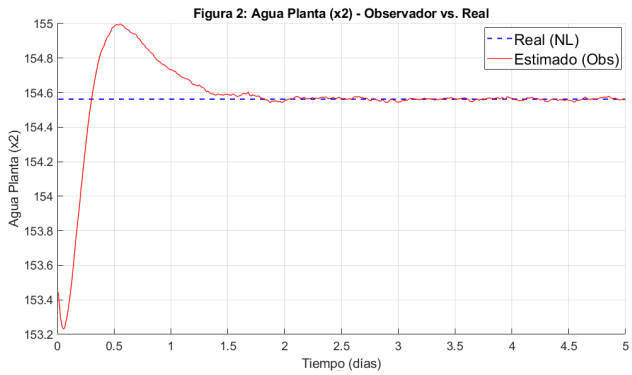

Fig.5 Estimación de w

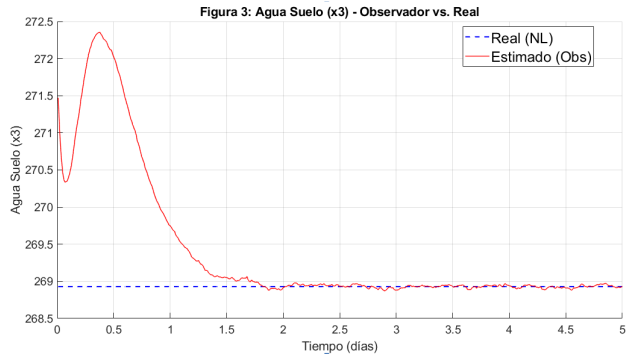

Fig.6 Estimación de v

Iniciando el error de estimación en valores de [2 -1 3], el observador converge rápidamente y el error de estimación cae a rangos de error normales (debido al ruido de medición).

4. OBSERVADOR DE ENTRADAS DESCONOCIDAS

Para el diseño de este estimador, se tiene que el modelo de la planta es:

$$\dot{x} = Ax + Bu + Dv, \qquad y = Cx \tag{35}$$

En nuestro caso, tomamos nuestra entrada desconocida como nuestra entrada u. De esta manera, el término $B * u$ quedaría anulado, resultando en una planta que no tendría entradas desconocidas y cuya matriz D sería la mismas matriz B, tal que $D = B$.

Como se explicó en el apartado de estabilidad, para lograr que se cumpla la condición de enfrentamiento, la matriz C se debe tomar como $C = [0, 0, 1]$, es decir, medir el agua alrededor de la planta. Además, se debe tener en cuenta que, el rango de la matriz de observabilidad de es de 1, es decir, únicamente uno de los polos del sistema es modificable, el resto no. Recordemos que, la dinámica del error de entradas desconocidas tiene la siguiente forma:

$$\dot{z} = Nz + Ly + Gu \tag{36}$$

$$\hat{x} = z - Ey \tag{37}$$

Con dinámica de error:

$$e = \hat{x} - x \tag{38}$$

$$\dot{e} = \dot{z} - \dot{x} - E\dot{y} \tag{39}$$

El criterio de diseño utilizado para la selcción de los polos consistió en ubicar el único polo modificable considerablmente más lejos de los otros polos no modificables de la planta P*A, de esta forma la dinámica de este polo no afectaría a la planta por ser de transitorios más rápidos, pues si se ubicaba este único polo modificable por delante de aquellos polos estáticos, la convergencia del estimador sería considerablmenete más lenta.

De esta forma, nuestro polinomio deseado consta de dos polos no modificables (dos de ellos intrínsecos de la dinámica de la planta P*A). A continuación se muestran los polos de la planta P*A:

$$\lambda_{PA} = \begin{bmatrix} -1.0680 \\ -1.4410 \\ 0 \end{bmatrix}$$

Se observa que, dos de tres polos son negativos. Para nuestros polos deseados dejamos entonces los dos polos negativos fijos y cambiamos el últmo polo según lo explicado, tal que:

$$\lambda_{deseado} = \begin{bmatrix} -1.4410 \\ -1.0680 \\ -1.5000 \end{bmatrix}$$

De esta forma, podemos calcular nuestro vector de ganancias. Se debe recordar que, solo una de estas ganancias es ajustable y las otras dos son fijas debido al criterio de selección de los polos no modificables:

$$\det(sI - (PA - K_e C)) = P_d(s)\big|_R \tag{40}$$

$$P * A = \begin{bmatrix} -1.0661 & 9.4974 & 0 \\ -0.0001 & -1.4430 & 0.8337 \\ 0 & 0 & 0 \end{bmatrix}$$

Nuestro vector de ganancias quedaría:

$$K_{gain} = \begin{bmatrix} 0 \\ 0.8337 \\ 1.5000 \end{bmatrix}$$

Se muestra el valor de las matrices L, N y G necesarias para la construcción del modelo del observador:

$$L = \begin{bmatrix} 0 \\ 0.8337 \\ 0 \end{bmatrix}$$

$$N = \begin{bmatrix} -1.0661 & 9.4974 & 0 \\ -0.0001 & -1.4430 & 0 \\ 0 & 0 & -1.5000 \end{bmatrix}$$

$$G = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

Observamos que, la matriz G relaciona nuestro término de entradas conocidas, pero dado a que, en este caso no contamos con entradas conocidas, esta matriz es nula.

4.1 Resultados de simulación

A continuación se muestran los resultados de la simualción. Tenga en cuenta que, al igual que el observador de Luengerberg, se modeló un ruido en el sensor el cual podrá ser observado en los resultados de la cuantificación del error.

Esto se hace comenzando con un error de estimación diferente de cero con el fin de observar la convergencia del observador. Para esto se tomó un intervalo de 1.5 días debido a la rápida convergencia del osbervador en comparación del tiempo de establecimiento de nuestra planta.

Error inicial de estimación diferente de 0:

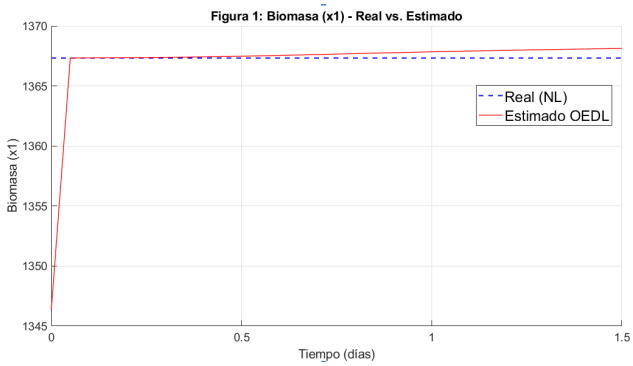

Fig.7 Estimación de x

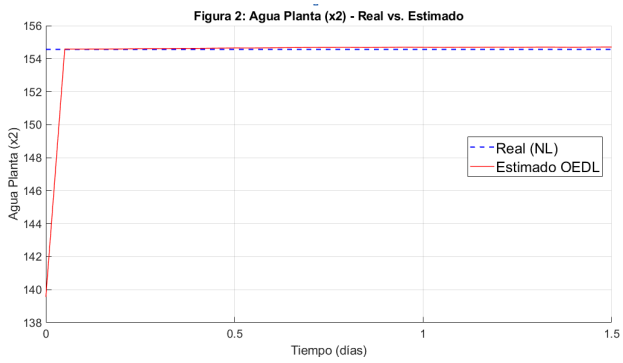

Fig.8 Estimación de w

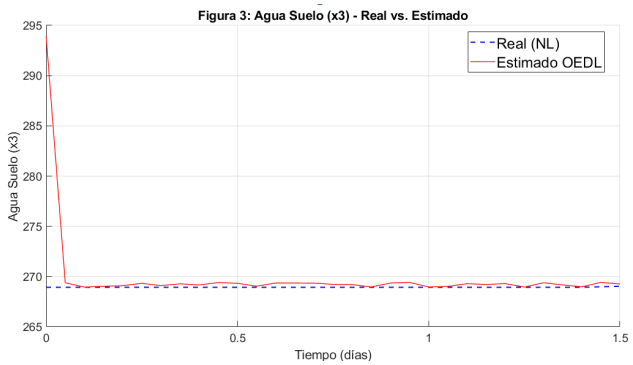

Fig.9 Estimación de v

Iniciando el error de estimación en valores de [-21 -15 25], el observador converge rápidamente y el error de estimación cae a rangos de error normales (debido al ruido de medición). De hecho, converge tan rápido que la escala de medición que debemos utilizar es mínima en relación a las magnitudes de nuestro modelo.

Los pequeños desfases existentes entre el observador y la planta real se debe principalmente al ruido de medición introducido. Este error de medición aumentará en proporción a la magnitud del ruido.

5. FILTRO DE KALMAN DISCRETO

Dado que el filtro de Kalman ha sido estudiado ampliamente horas de clase, se explicarán rápidamente los cálculos más relevantes y el criterio de elección para las matrices de covarianza y se omitirá la explicación detallada del algoritmo y las matrices dinámicas.

A diferencia de otros observadores, el filtro de Kalman es una herramienta principalmente estocástica cuyas ganancias varían cosntantememnte de forma dinámica.

Inicialmente, se debe convertir el modelo de nuestra planta lineal a un modelo discreto de la siguiente forma:

$$x_k = F_{k-1}x_{k-1} + G_{k-1}u_{k-1} + w_{k-1}, \tag{41}$$
$$y_k = H_k x_k + v_k. \tag{42}$$

Observamos que todas nuestras variables y matrices ahora son discretas. Incluímos también unos ruidos o incertidumbres asociadas al modelo y la medición (w y v resepctivamente)

Para discretizar nuestras matrices utilizamos la siguiente transformación:

$$F_k = I + A_{\text{cont}}dt \tag{43}$$

$$G_k = B_{\text{cont}}dt \tag{44}$$

Donde dt corresponde con mi intervalo de muestreo para mis variables medidas que a su vez fijan el periodo de muestreo para mis variables estimadas, las matrices de covarianza y demás parámetros en el filtro, es decir, marcan el"ritmo" de funcionamiento del filtro. La matriz H_k no necesita ser discretizada, pues realmente es la misma matriz C cuya función es realizar una medición

instantánea en el momento 'k' del estado. No depende del tiempo ni la dinámica.

Los criterios de elección para la matriz de covarianzas R y Q dependen exclusivamente de las incertidumbres asociadas a los isntrumentos de medición (asociados al ruido v) y a la incertidumbre del modelo respectivamente (asociados a la varianza w).

Múltiples fuentes como (Gitelson 2013; Haboudane 2004), (Evett 2008; Seyfried 2005) y (Offenthaler 2001) indican que, típicamente la incertidumbre de instrumentos de medición usados en agricultura suelen estar en rangos del 2-10% 0.02-0.1. El valor seleccionado fue de 0.05 presente en el rango aceptado para la matriz de covarianza R.

La matriz del modelo Q asigna incertidumbre baja a biomasa y agua en planta, coherente con modelos fisiológicos clásicos (Thornley & Johnson 1990; Tyree & Zimmermann 2013), y mayor incertidumbre a humedad en suelo, donde la variabilidad es naturalmente alta (Feddes 1978; van Genuchten 1980).

$$Q = \begin{bmatrix} 0.0100 & 0 & 0 \\ 0 & 0.0100 & 0 \\ 0 & 0 & 0.0500 \end{bmatrix}$$
$$R = [0.0025]$$

Cabe resaltar que, inciamos la matriz de covarianzas P en valores aleaotiros y a medida que corre el algoritmo, esta matriz se actualiza de forma dinámica.

5.1 Resultados de simulación

Se mostrará el filtro con dinámica de error inicial diferente de cero. Se mostrará en un intervalo de máximo 5 días con el fin de verificar plenamente la dinámica de convergencia de nuestro obervador.

A diferencia de los anteriores estimadores, y dado que esta herramienta también tiene el objetivo de filtrar la señal, decidimos utilizar ruidos bastante agresivos modificando manualmente las matrices R y Q temporalmente para observar como se genera el filtrado.

Error inicial de estimación diferente de 0 (sin ruido agresivo):

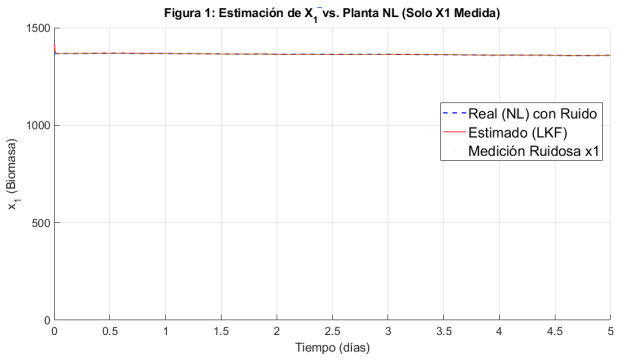

Fig.10 Estimación de x

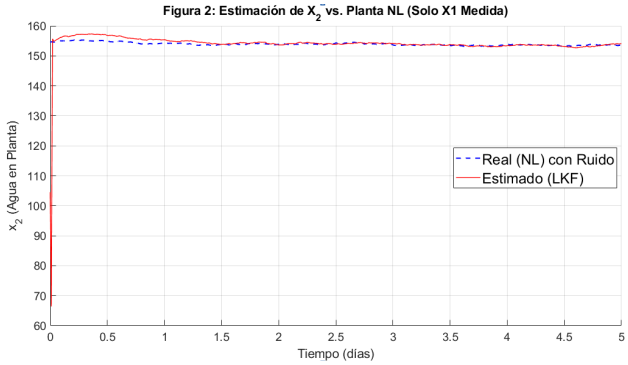

Fig.11 Estimación de w

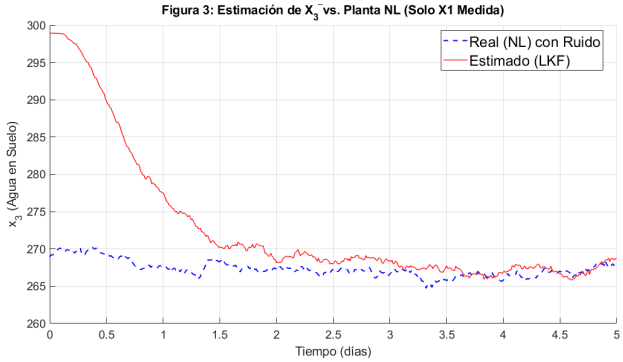

Fig.12 Estimación de v

Iniciando el error de estimación en valores de [50,-50,30], el filtro converge rápidamente y mantiene su función de filtrado incluso con el ruido del sistema. El error de la variable medida tiene un orden considerablemente menor debido a que la medición está siendo realizada y comparada en cada iteración.

Se observa también como el filtro realiza estimaciones suaves a pesar de encontrarse en un entorno ruidoso. Además, el error de estimación tiene un comportamiento normal alrededor de un valor esperado.

6. OBSERVADOR POR MODOS DESLIZANTES

Se conluye con el observador por modos deslizantes, debemos expresar nuestro sistema en dos partes, la medible y la no medible, tal que:

$$\dot{y} = A_{11}y + A_{12}x_1 + B_1u \tag{45}$$
$$\dot{x_1} = A_{21}y + A_{22}x_1 + B_2u \tag{46}$$

Donde y corresponde con la parte medible de nuestro sistema y x_1 con la variable no medible.

Tenemos que nuestro observador tendrá la siguiente forma:

$$\dot{\hat{y}} = A_{11}\hat{y} + A_{12}\hat{x_1} + B_1u + L_1 sign(y - \hat{y}) \tag{47}$$

$$\dot{\hat{y}} = A_{21}\hat{y} + A_{22}\hat{x_1} + B_2u + L_1L_2 sign(y - \hat{y}) \tag{48}$$

Tenemos dos dinámicas de error para este observador, una para la parte medible y otra para la no medible.

$$\dot{e_y} = y - \dot{y} \tag{49}$$

$$\dot{e_y} = A_{11}e_y + A_{12}\hat{e_{x1}} - L_1 sign(e_y) \tag{50}$$

$$\dot{e_{x_1}} = \dot{x_1} - \dot{\hat{x_1}} \tag{51}$$

$$\dot{e_{x_1}} = A_{22}e_{x_1} - L_1 L_2 sign(y - \hat{y}) \tag{52}$$

Una vez el error para la parte medible es cero, la dinámica del error para la parte no medible converge a través de la superficie deslizante la cual definimos como el plano (o líneas de nivel para cada variable independiente) cuando el error de la parte no medible es cero ($e_y = 0$), al sustituir y operar un poco tenemos que:

$$\dot{e_{x_1}} = (A_{22} - L_2 A_{12})e_{x_1} \tag{53}$$

Al utilizar las diferentes dinámicas del error y definiendo la superficie deslizante como la dinámica del error cuando la parte medible tiende a cero tal que:

$$S(e) = x_1 - \hat{x}_1 = e_{x_1} = 0 \tag{54}$$

Observamos entonces que la matriz L1 que define la fuerza de conmutación del término **sign**$(\cdot)$ y ayuda a que el error de la variable medida (e_{x_1}) alcance en tiempo finito hacia la superficie $e_{x_1} = 0$. Este valor al ser lo suficientemente grande para vencer la cota de incertidumbres y perturbaciones (como el ruido de medición o las no linealidades) pero a cambio, tendrá mucho chattering. Un valor extremadamente pequeño no será capaz de alcanzar la superficie y el tiempo de convergencia se verá afectado:

$$L_1 > |A_{11}e_y + A_{12}e_{x_1} + \Delta| \tag{55}$$

Dado que las dinámicas del error tienden a cero, la selección de L_1 queda determinada por las incertidumbres. Suponiendo que, la incertidumbre de nuestros instrumentos es de aproximadamente $[-0.25, 0.25]$, se ha seleccionado un valor 10 veces más grande al tamaño de este intervalo, tal que $L_1 = 5$.

L2 asigna los polos de la dinámica de error de los estados no medidos (e_{x_2} y e_{x_3}) cuando el sistema ya se está deslizando sobre la superficie. Para este caso hemos elegido los valores de -1.5 y -2.0, siendo el polo dominante -1.5 y asegurando que converja en un tiempo de establecimiento lo suficientemente rápido de $4/(-1.5)$. La ubicación de estos polos se hace de forma idéntica a como se haría en el observador de Luengerberg:

$$\lambda(A_{22} - L_2 A_{12}) = (-1.5, -2.0) \tag{56}$$

$$det(sI - (A_{22} - L_2 A_{12})) = P_{deseado}(s) \tag{57}$$

La matriz L2 y ganancia total del sistema obtenidas:

$$L_2 = \begin{bmatrix} 0.2156 \\ 0.3748 \end{bmatrix}$$

$$L = \begin{bmatrix} 5.0000 \\ 1.0781 \\ 1.8739 \end{bmatrix}$$

6.1 Resultados de la simulación

Se muestran los resultados de la simulación con un error de estimación inicial diferente de cero.

Como dato extra, para la muestra de estos resultados se evita graficar el error de estiamción (a diferencia de los otros estimadores) y se mostrará el diagrama de fase del error el cual muestra un comportamiento más interesante del error.

Error inicial de diferente de 0:

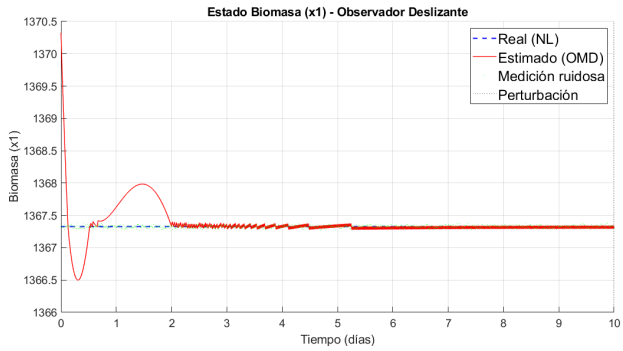

Fig.13 Estimación de x

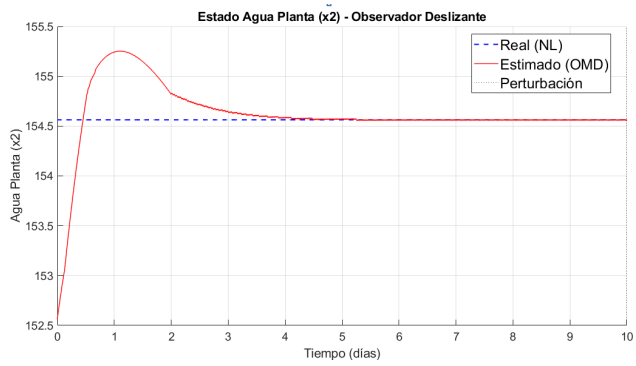

Fig.14 Estimación de w

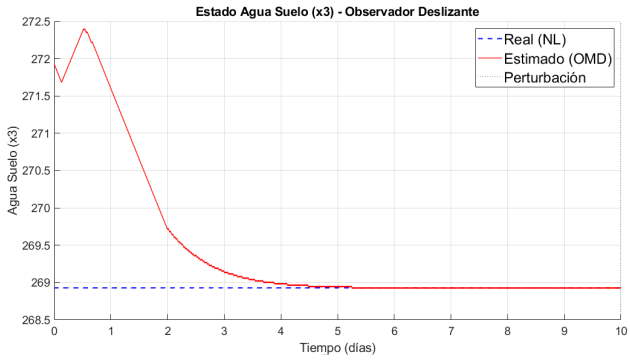

Fig.15 Estimación de v

Se aprecia como nuestro observador se mantiene en el estado estimado y responde perfectamente a la perturbación operando en condiciones iniciales iguales a 0.

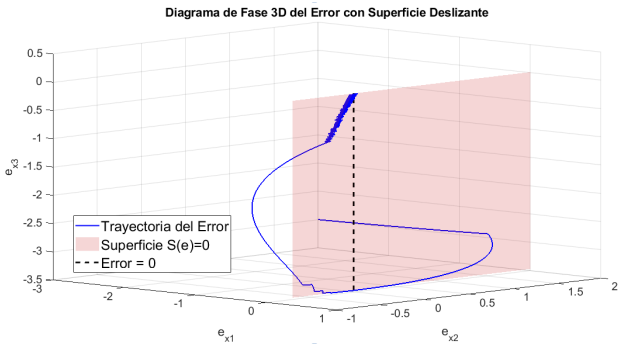

Fig.16 Diagrama de fase

Nuestro observador se comporta de forma esperada. El valor de L1 es el suficiente para capturar el estado no medible a la superficie deslizante superando todas las perturbaciones o no linealidades, y una vez este alcanza la superficie deslizante, comienza la conmutación de alta frecuencia que hace converger el error del estado no medible a cero rápidamente deslizándose.

7. CONCLUSIONES

El desarrollo de este trabajo ha permitido validar la aplicabilidad de la teoría de estimación de estados sobre un modelo agro-hidrológico complejo basado en el concepto SPAC (Soil–Plant-Atmosphere–Continuum). A partir del análisis, diseño y simulación de las diferentes estrategias, se derivan las siguientes conclusiones principales:

(1) **Validez de la aproximación lineal:** A pesar de la naturaleza altamente no lineal de las interacciones biomasa-agua, la linealización del modelo alrededor de puntos de equilibrio definidos por el nivel de riego (u_{eq}) demostró ser una aproximación robusta. Las simulaciones evidenciaron que, ante perturbaciones típicas, el error entre el modelo lineal y el no lineal se mantiene acotado (aproximadamente en un 0.14%), lo cual legitima el uso de técnicas de diseño lineal para la estimación de estados en rangos operativos de riego entre 1.5 y 4.0 mm/día.

(2) **Condicionantes de Observabilidad e Instrumentación:** El análisis de observabilidad reveló una restricción crítica en la selección de sensores. Mientras que para el Observador de Luenberger y el Filtro de Kalman la medición de la biomasa (x_1) fue suficiente para reconstruir el estado completo, el diseño del Observador de Entradas Desconocidas (UIO) exigió un cambio en la estrategia de medición. Fue necesario medir la humedad del suelo (x_3, cambiando la matriz C a $[0, 0, 1]$) para satisfacer la condición de rango o enfrentamiento necesaria para desacoplar la entrada desconocida. Además, se determinó que para el UIO el sistema no es completamente observable, pero sí detectable, lo cual fue suficiente para estabilizar la dinámica del error.

(3) **Desempeño del Observador de Luenberger:** Este estimador funcionó como una línea base efectiva, demostrando estabilidad asintótica en prácticamente todo el rango de operación (exceptuando singularidades matemáticas puntuales no operativas). Sin embargo, su desempeño es limitado en términos de velocidad de convergencia, siendo más lento en comparación con las técnicas avanzadas, lo que podría restringir su uso en aplicaciones que requieran respuestas rápidas ante cambios bruscos.

(4) **Robustez vs. Sensibilidad al Ruido (UIO vs. Kalman):** Se evidenció un compromiso de diseño (trade-off) claro. El Observador de Entradas Desconocidas logró converger relativamente rápido y desacoplar las perturbaciones de riego no medidas, pero mostró una alta sensibilidad al ruido de los sensores. Por el contrario, el Filtro de Kalman ofreció el mejor desempeño integral en escenarios realistas, logrando una convergencia adecuada y, crucialmente, filtrando el ruido de medición y proceso, lo que lo convierte en la opción más viable para implementación física con sensores económicos.

(5) **Eficacia de los Modos Deslizantes:** El Observador por Modos Deslizantes (SMO) presentó la dinámica más agresiva y eficiente en términos de rapidez, logrando una convergencia extremadamente rápida (teóricamente en tiempo finito para la variable medida). Esto lo posiciona como la mejor alternativa cuando se requiere robustez ante incertidumbres paramétricas severas, siempre y cuando el sistema de adquisición de datos pueda manejar la naturaleza conmutada de la corrección.

En resumen, este trabajo concluye que no existe un estimador único ideal para el modelo SPAC; la elección depende de la instrumentación disponible (sensor de biomasa vs. humedad de suelo) y del entorno operativo (presencia de ruido vs. entradas de agua desconocidas).

8. REFERENCIAS

REFERENCES

Allen, R.G., Pereira, L.S., Raes, D., and Smith, M. (1998). *Crop Evapotranspiration – Guidelines for Computing Crop Water Requirements*, volume 56 of *FAO Irrigation and Drainage Paper 56*. FAO, Rome. URL `https://www.fao.org/3/x0490e/x0490e00.htm`.

Andarzian, B., Bannayan, M., Steduto, P., Mazraeh, H., Barati, M., Barati, M., and Rahnama, A. (2011). Validation and testing of the aquacrop model under full and deficit irrigated wheat production in iran. *Agricultural Water Management*, 100, 1–8. doi:10.1016/j.agwat.2011.08.023. URL `https://doi.org/10.1016/j.agwat.2011.08.023`.

Díaz-González, V., Rojas-Palma, A., and Carrasco-Benavides, M. (2022). How does irrigation affect crop growth? a mathematical modeling approach. *Mathematics*, 10(1), 151. doi:10.3390/math10010151. URL `https://doi.org/10.3390/math10010151`.

FAO (2015). Aquastat main database. URL `https://www.fao.org/aquastat`. Food and Agriculture Organization of the United Nations.

López-Jiménez, J., Wouwer, A.V., and Quijano, N. (2022). Dynamic modeling of crop–soil systems to design monitoring and automatic irrigation processes: A review with worked examples. *Wa-*

ter, 14(6), 889. doi:10.3390/w14060889. URL https://doi.org/10.3390/w14060889.

Romero, M., Luo, Y., Su, B., and Fuentes, S. (2018). Vineyard water status estimation using multispectral imagery from an uav platform and machine learning algorithms for irrigation scheduling management. *Computers and Electronics in Agriculture*, 147, 109–117. doi:10.1016/j.compag.2018.02.013. URL https://doi.org/10.1016/j.compag.2018.02.013.

Waller, P. and Yitayew, M. (2015). *Irrigation and Drainage Engineering*. Springer, Berlin. doi:10.1007/978-3-319-05846-3. URL https://doi.org/10.1007/978-3-319-05846-3.